Univerzitet u Sarajevu
Elektrotehnički fakultet
Predmet: Uvod u digitalnu obradu slike
Predmetni profesor: prof. dr Emir Sokić
Autor: Berina Biberović
Akademska godina: 2022/2023.

Tutorijal 4

Detekcija ivica na slici

Sobel operator

Sobel operator je operator diskretnog diferenciranja koji računa aproksimaciju gradijenta od funkcije intenziteta slike. Sobel operator kombinira Gaussovo izglađivanje i diferenciranje.

U sljedećem primjeru će biti pokazano kako iskoristiti Sobel operator da se dobiju ivice na slici. OpenCV ima ugrađenu funkciju `cv::Sobel` koja primjenjuje operator nad datom slikom, tako da mi ne moramo sami računati matrice i množiti ih koje Sobel operator traži. Ova implementirana funkcija unutar OpenCV-a je svakako optimizirana i dobro napisana.

```
#include <opencv4/opencv2/highgui.hpp>
#include <opencv4/opencv2/core/mat.hpp>
#include <opencv4/opencv2/imgproc.hpp>

int main() {

    // Ucitavanje slike:
    cv::Mat slika = cv::imread("../nonaka_miho.jpg", cv::IMREAD_COLOR);

    // Prebacivanje u grayscale:
    cv::Mat gray;
    cv::cvtColor(slika, gray, cv::COLOR_BGR2GRAY);

    // Dodavanje blura na grayscale sliku:
    cv::Mat blur;
    cv::GaussianBlur(gray, blur, cv::Size(3, 3), 0, 0, cv::BORDER_DEFAULT);

    // Sobel:
    cv::Mat sobel;
    int ddepth = CV_8U;
    cv::Sobel(blur, sobel, ddepth, 0, 1, 3, 1, 0, cv::BORDER_DEFAULT);

    cv::imshow("Originalna", slika);
    cv::imshow("Blur", blur);
    cv::imshow("Nakon Sobela", sobel);

    cv::waitKey();

    return 0;
}
```

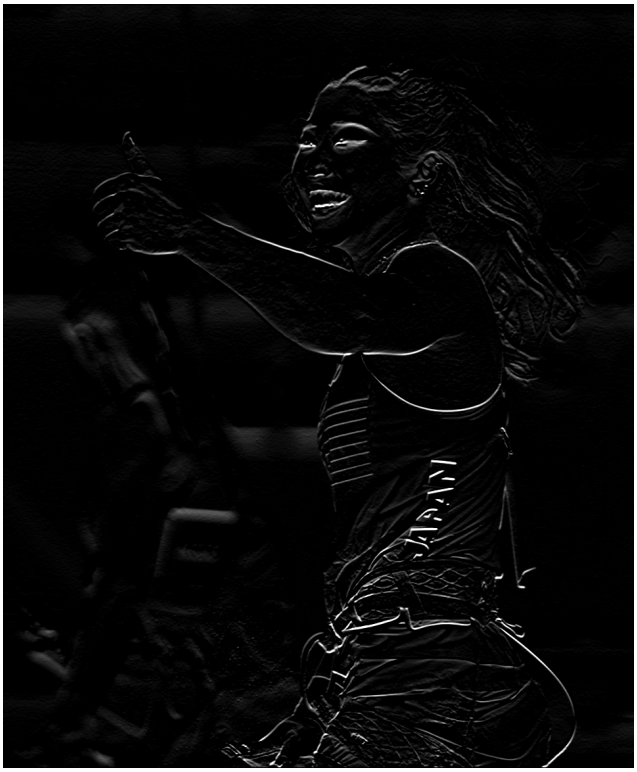
U gore navedenom kodu je prikazan postupak primjene Sobel transformacije u OpenCV-u. Prvo je potrebno učitanu sliku prebaciti u *grayscale*, nakon toga je potrebno uz pomoć `cv::GaussianBlur` funkcije primijeniti *blur* na sliku kako bi se šum odstranio sa slike (u ovom slučaju smo koristili kernel veličine 3×3. Nakon toga primjenjujemo Sobel funkciju u OpenCV-u kojoj prosljeđujemo *blur*-anu sliku, izlaznu sliku iz Sobela, dubinu izlazne slike, red izvoda po

x, red izvoda po y, veličinu kernela, *scaling* faktor za izračunate vrijednosti izvoda, vrijednost koja se dodaje na rezultate prije nego što se upiše u izlaznu sliku i način ekstrapolacije piksela.

Rezultati su prikazani na slikama 1 i 2. Vidimo da su uspješno prikazane ivice (obrisi) djevojke bijelom bojom na tamnoj pozadini.



Slika 1: Originalna slika[1]



Slika 2: Slika nakon Sobel transformacije

Canny operator

Canny detektor ivica je popularan algoritam kojeg je napravio John F. Canny. To je algoritam sa više etapa, u koje nećemo ulaziti detaljno u ovom tutorijalu. Ono što je nama važno jeste kako implementirati već gotovi Canny algoritam u OpenCV-u. OpenCV ima gotovu funkciju za Canny operator `cv::Canny`.

```
#include <opencv4/opencv2/highgui.hpp>
#include <opencv4/opencv2/core/mat.hpp>
#include <opencv4/opencv2/imgproc.hpp>

int main() {

    // Ucitavanje slike u grayscale-u:
    cv::Mat gray = cv::imread("../nonaka_miho.jpg", cv::IMREAD_GRAYSCALE);

    // Canny transformacija:
    cv::Mat canny;
    int t1, t2, aperture = 3;

    cv::namedWindow("Trackbars");
    cv::createTrackbar("Threshold 1", "Trackbars", nullptr, 255);
    cv::createTrackbar("Threshold 2", "Trackbars", nullptr, 255);

    do {
```

```
19
20          // Uzimamo vrijednosti t1 i t2 preko trackbarova:
21          t1 = cv::getTrackbarPos("Threshold 1", "Trackbars");
22          t2 = cv::getTrackbarPos("Threshold 2", "Trackbars");
23
24          cv::Canny(gray, canny, t1, t2, aperture, false);
25          cv::imshow("Canny - aperture = 3", canny);
26          cv::imshow("Grayscale slika", gray);
27
28      }while(cv::waitKey() != 'q');
29
30      return 0;
31  }
```

Prethodni isječak koda pokazuje kako se može iskoristiti `cv::Canny` funkcija kako bi se ivice slike mogle izdvojiti. Naime, bilo je potrebno ovdje napraviti *trackbar*-ove za treći i četvrti parametar koji prima funkcija, kako bi se što bolje izdvojile ivice. U ovakvom programu korisnik pomjeranjem *trackbar*-ova namiješta parametre za Canny operator. Bitno je naglasiti da je peti parametar koji prima funkcija stavljen fiksno na `aperture = 3`. Taj parametar se može mijenjati, ukoliko je to potrebno.

Zadatak 1

Korištenjem prethodnog koda naći ručno optimalne vrijednosti za parametre `t1` i `t2`.

Zadatak 2 - važan za testove

Istražiti OpenCV funkciju `cv::HoughLines` koja se koristi u laboratorijskoj vježbi broj 4. Nakon što istražite tu funkciju, primijenite je na proizvoljnu sliku koristeći Canny operator koji smo naučili na ovom tutorijalu. Kada dobijete linije kao rezultat funkcije `cv::HoughLines`, potrebno je da naučite kako ih iscrtati, što je dato u sljedećem isječku koda:

```
1      for(int i = 0; i < linije.size(); i++) {
2
3          double rho = linije[i][0], theta = linije[i][1];
4
5          cv::Point p1, p2;
6
7          double a = std::cos(theta), b = std::sin(theta);
8          double x0 = rho * a, y0 = rho * b;
9
10         p1.x = cvRound(x0 + 1000 * (-b));
11         p1.y = cvRound(y0 + 1000 * (a));
12         p2.x = cvRound(x0 - 1000 * (-b));
13         p2.y = cvRound(y0 - 1000 * (a));
14
15         // Iscrtavamo linije na slici crvenom bojom:
16         cv::line(slika_na_kojoj_iscrtavamo_linije, p1, p2, cv::Scalar(0, 0,
               255), 3, cv::LINE_AA);
17     }
```

Napomene

Korištena tema za prikaz C++ koda na tutorijalima je `solarized`[2].

Literatura

[1] KYODO NEWS. *Sport climber Nonaka Miho helps Noguchi make grand exit in Olympic debut*. https://english.kyodonews.net/tokyo/news/2021/08/2821034e18ae-nonaka-helps-noguchi-make-grand-exit-in-olympic-debut.html. Pristup stranici: 20. septembar 2023. 2021.

[2] Ethan Schoonover. *Solarized*. http://ethanschoonover.com/solarized. Pristup stranici: 20. maj 2023. 2011.